

Achtung: WebFetch war während der heutigen Recherche für jeden geprüften Host durchgehend blockiert (HTTP 403). Alle Fakten wurden stattdessen über mehrere unabhängige Suchtreffer kreuzverifiziert. Zudem ist für Montag, 03.08.2026, kein planmäßiger Lauf feststellbar; dadurch blieben einzelne Themen vom 01.-02.08. außerhalb des 24h-Fensters.

Praxis-News

1. Amazon: KI-Projekte laufen bei Kostenkontrolle „katastrophal teuer“ aus dem Ruder

Laut heise-Bericht vom 03.08.2026 überzog ein Amazon-Projekt, in dem Anthrups Claude Sonnet Autorentaten mit Einträgen auf der E-Commerce-Plattform abgleichen sollte, sein Budget um 860% auf 1,8 Mio. US-Dollar - die Kostenexplosion fiel erst nach fünf Monaten auf, das Projekt scheiterte am Ende komplett. Ein zweites Beispiel, ein Finanz-Audit-Tool, verursachte unerwartete Mehrkosten von 541.000 US-Dollar. Amazon zieht daraus die Lehre, dass Programmierfehler in KI-gestützten Systemen ungleich teurer werden als in klassischer Software, und arbeitet laut Financial-Times-Bericht an automatisierten Kostenschutzmechanismen für künftige Projekte.

heise.de

2. Alibaba veröffentlicht Qwen3.8-Max: 2,4-Billionen-Parameter-Modell für mehrtägige autonome Aufgaben

Alibabas Qwen-Team stellte am 03.08.2026 sein bislang leistungsfähigstes Modell vor: eine Mixture-of-Experts-Architektur mit 2,4 Billionen Gesamt- und rund 95 Milliarden pro Anfrage aktiven Parametern, verfügbar ab sofort über Alibaba Cloud; die Modellgewichte sollen laut Ankündigung in der kommenden Woche folgen. In Tests programmierte das Modell autonom Software, reproduzierte und verbesserte die Ergebnisse eines Forschungspapers und führte im eigens entwickelten „E-Commerce Bench“ 365 simulierte Tage lang eigenständig einen virtuellen Online-Shop: Aus 100.000 Yuan Startkapital wurden 416.252 Yuan - 38% mehr als beim Vergleichsmodell GLM 5.2 und mehr als doppelt so viel wie beim Vorgänger Qwen3.7-Max -, inklusive Lieferantenverhandlungen und Betrugserkennung unter 152 gezielt eingeschleusten Fake-Händlern.

the-decoder.de

Bedeutende Forschung

1. OpenAI-Feldbericht: KI-Agenten modernisieren maroden Forschungscode, Verifikation bleibt aber aufwendig

Ein am 03.08.2026 veröffentlichter Feldbericht von OpenAI mit akademischen Partnern dokumentiert acht Fallstudien, überwiegend aus der Biologie, in denen Forschungsgruppen Coding-Agenten wie Codex und teilweise Anthrups Claude Code einsetzten, um vernachlässigte Forschungssoftware zu modernisieren - mit bis zu 60-fachen Geschwindigkeitssteigerungen. Ein Beispiel: Eine RNA-Qualitätskontroll-Bibliothek, die für einen Datensatz zuvor knapp 16 Stunden brauchte, lief nach der Agenten-Überarbeitung in nur 15 Minuten. Laut den Beteiligten agieren die Systeme dabei „überzeugend und selbstsicher falsch“: Der Aufwand verschiebt sich von der Programmierung zur aufwendigen Prüfung wissenschaftlicher Korrektheit - in einem Statistik-Paket

rechnete die umgeschriebene Version zwar schneller, verwendete dabei aber den Kehrwert der eigentlich beabsichtigten Werte. Der Bericht ist laut The Decoder kein unabhängiges Audit, sondern eine Sammlung von Selbstauskünften der beteiligten Forschenden.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- Zwei Forscherteams lösen unabhängig dasselbe Quantenkryptographie-Problem mit GPT-5.6 Sol Ultra (01.08., außerhalb des 24h-Fensters)

(scientificamerican.com)

- EU startet Durchsetzung des AI Act: Transparenzpflichten (Art. 50) in Kraft, neue Sanktionsbefugnisse (02.08., außerhalb des 24h-Fensters)

(digital-strategy.ec.europa.eu)

- Meta AI: Zweiter KI-Agent als Gedächtnisstütze gegen wiederholte Fehler bei langen Aufgaben (02.08., außerhalb des 24h-Fensters)

(the-decoder.de)

- MiniMax H3: Erstes offenes Videomodell an der Spitze eines KI-Video-Rankings (31.07., außerhalb des 24h-Fensters)

(the-decoder.com)

- Landgericht München entscheidet im Urheberrechtsstreit GEMA gegen Suno überwiegend für GEMA (31.07., außerhalb des 24h-Fensters)

(gema.de)