

Praxis-News

1. OpenAI bringt ChatGPT-Desktop-App für Linux (Preview)

Die neue Linux-App vereint drei Bereiche: den klassischen ChatGPT-Assistenten, "ChatGPT Work" für mehrstufige Aufgaben mit Zugriff auf lokale Dateien sowie die Entwicklerumgebung Codex. Sie steht als DEB- und RPM-Pakete für x64 und ARM64 bereit, unterstützt werden Ubuntu 24.04/26.04 LTS, Debian 13 sowie Fedora 43/44. Damit schließt OpenAI die Lücke zu den bereits 2024 erschienenen macOS- und Windows-Versionen; der Rollout läuft weltweit im Preview-Status.

heise.de

2. Nvidia kündigt Nemotron 4 an: bis zu einer Billion Parameter geplant

Nvidia hat mit Nemotron 4 die nächste Generation seiner offenen Modellreihe angekündigt – noch kein Release, sondern eine Ankündigung ohne festen Termin, frühestens im Herbst zu erwarten. Das größte Modell der Familie soll mindestens eine Billion Parameter erreichen, doppelt so viele wie Vorgänger Nemotron 3 Ultra. Der Artikel ordnet das in den Wettbewerb mit chinesischen Modellen ein, die bereits größer seien (Deepseek V4 Pro: 1,6 Billionen, Kimi K3: 2,8 Billionen Parameter).

the-decoder.de

3. Mistral führt regionale Datenverarbeitung (EU/US) und Priority Tier ein

Mistral-Kunden können ab sofort zwischen europäischer (api.eu.mistral.ai) und US-amerikanischer (api.us.mistral.ai) Serververarbeitung wählen, gegen einen Aufschlag von 10 Prozent. Neu in der Testphase ist ein "Priority Tier" mit garantierter Verfügbarkeit von 99,5 Prozent bei Systemüberlastung, hier beträgt der Aufschlag 75 Prozent. Die Regionalitätsgarantie gilt laut Artikel nicht für Agenten, Batch-Verarbeitung, Dateiverwaltung, Kontoeinstellungen, API-Schlüssel und Abrechnung.

the-decoder.de

4. Microsoft veröffentlicht Code-Modell MAI-Code-1.1-Flash für GitHub Copilot

Microsoft hat den Nachfolger seines Code-Modells vorgestellt: 25 Prozent höhere Token-Effizienz und nur ein Viertel der Kosten des im Juni erschienenen Vorgängers. In den Benchmarks erreicht es 72,6 Prozent auf SWE-bench Verified und 62,9 Prozent auf Terminal-Bench 2.1 – damit bleibt es laut Artikel hinter Deepseek-V4-Flash-0731 zurück (82,7 Prozent auf Terminal-Bench), das mit 0,14 US-Dollar pro Million Input-Token zudem günstiger ist als Microsofts 0,20 US-Dollar.

the-decoder.de

Tipps & Tricks

1. Wiederverwendbare Prompts systematisch aus erfolgreichen Chats entwickeln

heise online beschreibt eine fünfstufige Methode, um aus einzelnen guten Chat-Dialogen dauerhaft nutzbare Prompt-Vorlagen zu machen: erfolgreiche Chats analysieren, daraus Vorlagen ableiten, diese iterativ verfeinern, zu einer persönlichen Prompt-Bibliothek ausbauen und schließlich zu mehrstufigen Workflows bzw. Prompt-Ketten erweitern. Der Artikel geht auch auf gängige Prompt-Frameworks und typische Anfängerfehler ein.

heise.de

2. Wartungsroutinen als nächtlichen Cron-Prompt statt manueller Aufgabe laufen lassen

Simon Willison stellt einen Ansatz von Entwickler David Crawshaw vor: Ein nächtlicher Cron-Job führt einen festen Prompt aus, der einen KI-Agenten anweist, Änderungen von Upstream zu holen, lokale Anpassungen darauf zu rebasen, die Funktionsfähigkeit zu prüfen und bei Erfolg die aktuelle Version zu ersetzen. Zitierter Prompt: "fetch upstream changes to the software and rebase all local changes on top of upstream. Check that

the software works as intended and replace the current version." Lässt sich auf beliebige eigene Wartungsroutinen übertragen.

simonwillison.net (englisch)

3. Zeitkritische Fakten explizit im System-Prompt verankern

Simon Willison dokumentiert einen Ausschnitt aus dem System-Prompt von Claude Opus 5, in dem Anthropic aktuelle, nach dem Trainings-Cutoff liegende Fakten explizit als Hinweistext einträgt, inklusive Anweisung zum Umgang damit. Wer eigene System-Prompts baut, kann das Muster übernehmen: zeitkritische Fakten nicht dem Trainingswissen überlassen, sondern explizit nennen und den Umgangston gleich mit vorschreiben.

simonwillison.net (englisch)

Bedeutende Forschung

1. Umfrage: KI-Tools zur Brustkrebserkennung bleiben hinter Erwartungen der Radiologen zurück

Eine in "Clinical Imaging" veröffentlichte Umfrage unter 215 Mitgliedern der Society of Breast Imaging (Leitung: Joud Almogati, UC San Diego Health) zeigt: Rund die Hälfte der Radiologen nutzt bereits FDA-zugelassene KI-Tools, elf Prozent planen den Einsatz. Die tatsächlichen Effekte bleiben unter den Erwartungen: Rückrufrate sank nur um 35 statt der erwarteten 59 Prozent, unnötige Biopsien nur um 9 statt 36 Prozent, Burnout-Reduktion nur um 29 statt 56 Prozent. Als Hauptgründe nennt die Umfrage übertriebene Branchenversprechen sowie Kosten und fehlende institutionelle Unterstützung.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- [OpenRouter Auto Router](https://openrouter.ai)
(openrouter.ai)
- [Qwen-KI-Integration in Apple Intelligence \(Leak, nur China\)](#)
(heise.de)
- [Gemini erreicht eine Milliarde monatliche Nutzer](#)
(heise.de)
- [CANON – kontrolliertes Englisch als Prompt-Notation-Framework](#)
(github.com)
- [#heiseshow: Diskussion zu KI-Wasserzeichen und EU-AI-Act-Transparenzpflichten](#)
(heise.de)
- [Verschlüsselter KI-Denkprozess als Orakel missbraucht \(Vertiefung, bereits gestern gemeldet\)](#)
(heise.de)