

Praxis-News

1. Google veröffentlicht Gemini 3.7 Flash mit verbesserten Coding-Benchmarks

Google hat mit Gemini 3.7 Flash sein bislang leistungsfähigstes Flash-Modell für Coding- und Agentenaufgaben veröffentlicht – nur drei Wochen nach Gemini 3.6 Flash. Bei FrontierCode 1.1 Main erreicht es 43,6 Prozent (Claude Sonnet 5: 42,7 Prozent, GPT-5.6 Terra: 41,3 Prozent), bei DeepSWE v1.1 liegt es mit 65,3 Prozent hinter GPT-5.6 Terra (69,6 Prozent) zurück; im WebDev Arena erzielt es einen Elo-Wert von 1588. Zum Einführungspreis bis 31.12.2026 kostet es 0,75 US-Dollar pro Million Input-Token und 3,75 US-Dollar pro Million Output-Token (regulär 1,50/7,50 US-Dollar).

heise.de

2. DeepSeek veröffentlicht V4-Pro-0813, erhöht API-Preise und macht Agentensoftware Open Source

DeepSeek hat das Modell-Build V4-Pro-0813 veröffentlicht (verfügbar über App, Web und API) mit einstellbarer Reasoning-Intensität (niedrig/hoch/maximal) und nativer Unterstützung der OpenAI-Responses-API. Die Leistung stieg deutlich: im Terminal Bench 2.1 von 72,1 auf 87,9 Punkte, im DeepSWE-Benchmark von 12,8 auf 62,7 Punkte, im Artificial Analysis Intelligence Index von 45 auf 53 Punkte (zum Vergleich Claude Opus 5: 63 Punkte). Ab dem 16.08.2026, 16 Uhr UTC, gelten neue Peak-/Off-Peak-Preise (Off-Peak-Input z. B. 0,66 statt bisher 0,435 US-Dollar pro Million Token); zusätzlich veröffentlicht DeepSeek seine Agentensoftware „Deepseek Harness v0.1“ unter MIT-Lizenz als Open Source, inklusive Plugin-System „Cordis“.

the-decoder.de

3. Anthropic bringt Claude Cowork ins Chrome-Seitenpanel

Anthropic hat Claude Cowork in das Seitenpanel der Chrome-Erweiterung integriert und ermöglicht damit erstmals die Nutzung von Skills, Plugins und Connectors direkt im Browser ohne zusätzliche Einrichtung. Claude kann auf der aktuell geöffneten Webseite recherchieren und daraus Ausgabedateien wie Excel- oder PowerPoint-Dokumente erstellen, etwa zur Extraktion von Kennzahlen aus Analytics-Dashboards; vor Käufen fragt Claude vorab nach. Anthropic warnt zugleich vor Sicherheitsrisiken durch versteckte Anweisungen auf Webseiten und rät von der Nutzung bei Banking- und Gesundheitsdaten ab. Verfügbar ist die Funktion sofort über den Chrome Web Store für alle bezahlten Pläne.

the-decoder.de

4. Ant Group veröffentlicht offenes Modell Ling 3.0 Flash

Ant Groups Forschungseinheit inclusionAI hat mit Ling 3.0 Flash ein offenes Modell veröffentlicht, das laut Artikel „das intelligenteste offene Modell unter 124 Milliarden Gesamtparametern“ ist und dabei deutlich weniger aktive Parameter nutzt als vergleichbare Systeme. Im Artificial Analysis Intelligence Index erreicht es 38 Punkte (gleichauf mit Qwen3.6 27B), die Halluzinationsrate im AA-Omniscience-Test sank von 97 auf 44 Prozent. Das Modell steht unter MIT-Lizenz über die inclusionAI-API, DeepInfra und Hugging Face bereit, die Modellgewichte sind direkt auf Hugging Face abrufbar.

the-decoder.de

Tipps & Tricks

1. Fremden Code per „Clone-Prompt“ verstehen lassen statt selbst zu bauen

Simon Willison beschreibt einen Workflow, den er nach eigener Aussage mehrmals täglich nutzt: In einem normalen Claude-Chat lautet der Auftrag schlicht „Clone x/y from GitHub and tell me how Z works“, um die Funktionsweise fremder Software zu verstehen. Kompilieren und Setup überlässt er dabei komplett dem Coding-Agenten und behandelt das als „a zero time investment challenge: tell Codex or Claude Code to checkout and build X and then come back ten minutes later“. Sein Argument: Erst KI-Assistenten lösen das

ursprüngliche Open-Source-Versprechen – jeder kann den Code prüfen und verstehen – praktisch ein, weil die Zeithürde für Setup und Build wegfällt. Da keine deutschsprachige Quelle zu diesem konkreten Workflow existiert: Willison nutzt die Technik eigenen Angaben zufolge „several times a day“ für unbekannte Repositories.

simonwillison.net

Bedeutende Forschung

1. KI-Forscher sehen erste Etappenziele auf dem Weg zur autonomen Selbstverbesserung erreicht

Der IAPS-Fellow Severin Field hatte im Spätsommer 2025 25 Forschende von OpenAI, Anthropic, Google DeepMind, Meta und US-Universitäten zu rekursiver Selbstverbesserung (RSI) von KI befragt; 20 der 25 Befragten stuften die Automatisierung der KI-Forschung als eines der schwerwiegendsten Risiken ein. Laut Artikel verdoppelt sich die Dauer autonom bewältigbarer KI-Agent-Aufgaben (Task-Horizon-Benchmark) seit 2019 etwa alle sechs Monate, seit 2024 möglicherweise alle vier Monate. Nur 4 von 20 Befragten erwarteten forschungsfähige Modelle als öffentliche Produkte; laut Artikel schreibt Anthropic Modell „Claude Mythos“ mittlerweile über 80 Prozent des Codes für Anthropic's Produktions-Codebasis. Als seit den Interviews erreichte Meilensteine nennt Field u. a. Goldmedaillen bei der Mathe-Olympiade, von Menschen begutachtete Workshop-Papers durch KI-Systeme und autonome Trainingszyklen durch Agenten-Setups.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- Suno Studio 2.0: Chat-Steuerung für Musikproduktion

(the-decoder.de)

- Worldclaw (Tencent): KI-Tool generiert per Ein-Zeilen-Prompt 3D-Welten (außerhalb 24h-Fenster)

(arxiv.org)

- Unsichtbarer Prompt-Injection-Text als Verifikations-Kniff gegen ungeprüfte KI-Antworten (Datum unklar)

(t3n.de)