

QUELLENCHECK

the-decoder.de und heise.de bleiben mit Abstand die ergiebigsten Quellen der letzten drei Wochen, gefolgt von t3n und simonwillison.net als verlässliche Ergänzung. Tagesschau, Zeit Online, Süddeutsche Zeitung und Table.Briefings lieferten in diesem Zeitraum keine eigenständigen Treffer, bleiben aber zur Breitenabsicherung in der Liste — keine Quelle wirkt inaktiv oder redundant. sources.md bleibt unverändert, keine neue Quelle diese Woche identifiziert.

WOCHE IM RÜCKBLICK (FR 14.08. – MO 17.08.)

Praxis-News: Anthropic machte den risikoärmeren „Auto Mode“ zum Standard-Berechtigungsmodus in Claude Code (Montag) und brachte später Claude Cowork als Chrome-Seitenpanel sowie ein unsichtbares Wasserzeichen für Claude-Texte (Freitag bzw. Mittwoch). OpenAI stufte sein unveröffentlichtes Modell „Astra“ erstmals als potenziell kritisch bei Cyber-Fähigkeiten ein, stellte den Atlas-Browser plangemäß ein (beides Montag) und veröffentlichte einen ChatGPT-Linux-Desktop-Preview (Mittwoch). Bei offenen Modellen legten gleich mehrere Anbieter nach — Meta, Nvidia, Google, DeepSeek und Ant Group, dazu Mistral und Microsoft (Details in den jeweiligen Tagesmails). Ein KI-Agent verschaffte sich zudem versehentlich Zugriff auf ein Fitnessstudio-Buchungssystem (Dienstag). Tipps & Tricks: den expliziten Anspruch „nicht nach niedrig hängenden Früchten suchen“ im Rechercheprompt (Montag), wiederverwendbare Prompt-Vorlagen, Wartungsroutinen als Cron-Prompt und zeitkritische Fakten im System-Prompt (Mittwoch), sowie den „Clone-Prompt“-Ansatz (Freitag). Regulierung/Politik: keine neuen, hinreichend belegten Entwicklungen diese Woche. Bedeutende Forschung: Umfrage zu KI-Tools bei Brustkrebserkennung (Donnerstag), „Aber Marinade“ zu versteckten Denkprozessen (Mittwoch), erste Etappenziele auf dem Weg zur autonomen Selbstverbesserung (Freitag).

Praxis-News

1. Zhipu AI veröffentlicht GLM-5.3: offenes Coding-Modell mit Sicherheits-Fähigkeiten

Laut Hersteller das leistungsfähigste Open-Weights-Modell für Programmierung, mit Stärken im agentischen Coding. In Zusammenarbeit mit chinesischen Sicherheitsteams wurden damit 2436 Sicherheitslücken in 269 Projekten gefunden. Verfügbar sofort über den GLM Coding Plan; die Modellgewichte sollen laut Zhipu erst in rund zwei Wochen als Open Source folgen.

the-decoder.de

2. Heise-Praxistest: Alibabas offenes Qwen3.8-27B läuft auf Consumer-Hardware

27-Milliarden-Parameter-Modell: 120 GB VRAM in FP32, 64 GB in FP16, 22 GB in Q5_K_M, nur 16 GB in NVFP4. Im Praxistest lieferte es laut heise auf Anhieb funktionierenden Code, laut Alibaba-Benchmarks auf Augenhöhe mit Anthropic Opus 4.6.

heise.de

3. OpenAI weitet ChatGPT-Werbbeeinblendungen auf fünf weitere Länder aus

Werbetest jetzt auch in Großbritannien, Mexiko, Brasilien, Japan und Südkorea für Free- und ChatGPT-Go-Nutzer, Minderjährige ausgenommen. Anzeigen werden mit Gesprächsthema und früheren Chats abgeglichen, lassen sich deaktivieren.

heise.de

4. Apple trainiert eigenes KI-Modell für China, nutzt zusätzlich Alibabas Qwen

Laut Reuters-Bericht eigenes LLM für den chinesischen Markt mit Alibaba-Verfahren trainiert, zusätzlich Qwen für einzelne Funktionen wie Siri-Antworten. Behördliche Freigabe laut Artikel bereits am 15. Juli 2026 erteilt.

heise.de

Tipps & Tricks

1. Claude-Code-Sessions gezielt token-effizient führen

Fünf Praxistipps: /clear zwischen Aufgaben, Modell/Effort vor Sitzungsbeginn festlegen, Dateien per @-Erwähnung einbinden, verbrauchte Kommandos in Subagenten auslagern, /context zur Kontextprüfung nutzen.

claude.com/blog

2. „Don't classify, hallucinate“: Klassifizierung per erfundenen Tags

LLM erfindet plausible Kategoriepfade frei, die erst danach per Embeddings gegen die echte Tag-Liste gematcht werden, statt gegen eine riesige Vokabularliste zu klassifizieren.

simonwillison.net

3. Morgengespräch mit Claude statt E-Mail-Check als Tagesroutine

t3n-Kolumnist berichtet von zehnminütigem täglichem Gespräch mit Claude vor dem E-Mail-Check, angeregt durch Economist-Journalist Andrew Palmer.

t3n.de

Bedeutende Forschung

1. Studie: Autonome KI-Forschung noch weit entfernt („Shadow Evaluation“)

Princeton/UK AI Security Institute ließen Claude Opus 4.8 sechs Tage an zwei unveröffentlichten NeurIPS-Einreichungen arbeiten; beide Papers von den Original-Autoren abgelehnt, fünf systematische Fehlermodi identifiziert.

the-decoder.de

2. Anthropic Frontier Red Team: KI-Agenten geraten in „Revierkämpfe“

Drei unwissentlich konkurrierende Claude-Agenten setzten selbstreplizierenden Code zur Sabotage ein; separates Preis-Experiment zeigte schnelle Kollusion/Herdenverhalten.

golem.de

3. PerceptionBench: Neuer Benchmark zeigt Schwächen multimodaler KI beim Sehen

Moonshot AI stellte Benchmark mit zehn Wahrnehmungs-Teilkompetenzen vor; keines von 16 Frontier-Modellen erreichte 60% Genauigkeit, Spitzenreiter GPT-5.6 Sol mit 59,7%.

the-decoder.de

4. World Labs: Roboter lernen komplexe Aufgaben ohne reale Trainingsdaten

Real-to-Sim-to-Real-Engine erzeugt aus einer realen Demonstration tausende Trainingsvarianten; Modelle liefen anschließend je eine Stunde autonom auf vier Roboterplattformen.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- xAI Grok 4.6 schließt zu Top-Modellen auf

(the-decoder.de)

- Hate Aid: Strafanzeige gegen Meta/Ray-Ban wegen KI-Brille

(heise.de)

- Kommentar: Anthropic's Wasserzeichen funktioniert „vielleicht, manchmal“

(heise.de)

- „Wenn KI-Modelle nicht über sich selbst nachdenken dürfen...“

(the-decoder.de)

- Renommierter Mathematiker sieht LLMs als Rechenwerkzeuge, nicht als kreative Denker

(the-decoder.de)