

Praxis-News

1. Perplexity bringt lokalen KI-Agenten "Portable Computer" auf Nvidia-Hardware

Perplexity hat mit "Portable Computer" einen vollständig lokal laufenden KI-Agenten vorgestellt: Modell, Planer, Tool-Steuerung und Dateisuchindex laufen komplett auf dem eigenen Gerät, Daten verlassen es nur nach expliziter Freigabe. Start ist zunächst auf der Nvidia-DGX-Spark-Workstation (ab 4.700 US-Dollar) unter Linux, später sollen auch Windows-PCs mit RTX-GPUs ab 24 GB VRAM folgen; genutzt werden u. a. die Modelle Qwen 3.8 27B und PPLX 27B. Voraussetzung ist ein Pro- oder Max-Abo, die lokale Ausführung selbst verbraucht aber keine Credits – laut internen Benchmarks liegt die Erfolgsquote je nach Modell bei 82,6 bzw. 85,4 Prozent auf 53 Testaufgaben.

heise.de

2. Alibaba veröffentlicht Qwen3.8-Flash-Next als Kosten-Vorschau auf Qwen4

Alibaba hat mit Qwen3.8-Flash-Next ein Mixture-of-Experts-Modell mit 125 Milliarden Gesamt- und nur 6 Milliarden pro Token aktivierten Parametern vorgestellt, das als "architektonische Vorschau" auf Qwen4 dient. Es nutzt eine neuartige N-Gram-Embedding-Schicht mit 51 Milliarden Parametern, die im RAM statt auf der GPU liegt, und bietet nativ 262.144 Token Kontext, per YaRN erweiterbar auf 1 Million. Über QwenCloud kostet es 0,16 US-Dollar je Million Input- bzw. 0,47 US-Dollar je Million Output-Token – etwa ein Zwölftel des Preises des Flaggschiffs Qwen3.8-Max. Die Modellgewichte stehen offen auf Hugging Face und ModelScope bereit.

the-decoder.de

3. IBM veröffentlicht offene Granite-4.2-Modelle mit agentenbasiertem Training

IBM hat drei neue Granite-4.2-Sprachmodelle in den Größen 3, 8 und 30 Milliarden Parameter veröffentlicht, trainiert mit rund 15 Billionen Token und Kontextfenstern bis zu 512.000 Token. Die 8B- und 30B-Varianten durchliefen zusätzlich "agentisches RL"-Training in echten Sandbox-Umgebungen (Tool-Nutzung, Code schreiben und ausführen, Web-Suche) und bieten umschaltbare Thinking-, Non-Thinking- und Low-Effort-Modi sowie natives Tool-Calling im OpenAI-Format. Die Modelle stehen unter Apache-2.0-Lizenz auf Hugging Face, Ollama und GitHub bereit; parallel erschien mit Granite Speech 5.0 Turbo CTC ein 470-Millionen-Parameter-Modell, das laut IBM drei Stunden Audio in einer Sekunde transkribiert – doppelt so schnell wie bisherige Bestwerte.

the-decoder.de

Regulierung/Politik

1. UN und Rotes Kreuz fordern verbindliches Verbot für autonome Waffensysteme

UN-Generalsekretär António Guterres und ICRC-Präsidentin Mirjana Spoljaric Egger haben in einer gemeinsamen Erklärung aus Genf den sofortigen Beginn zwischenstaatlicher Verhandlungen für ein rechtsverbindliches Instrument gegen autonome Waffensysteme gefordert. Verlangt werden klare Verbote für Systeme, deren Verhalten Bediener nicht zuverlässig vorhersehen können, sowie für autonome Waffen, die gezielt Menschen als Ziel auswählen. Als konkreten Termin nennen beide die im November 2026 anstehende Überprüfungskonferenz der UN-Waffenkonvention in Genf, bei der Staaten verbindliche Beschränkungen beschließen sollen. Widerstand kommt laut Bericht von Militärmächten wie Russland, den USA und Israel, die sich gegen konkrete Vereinbarungen sperren.

heise.de

Weitere gesichtete, aber ausgelassene Punkte

- Ox Alpha enthüllt sich vermutlich als GLM-5.3-Flash (Zhipu AI)
(heise.de)

- Nvidia kündigt Jetson Orin Nano 2 für Roboter an (Marktstart erst 2027)
(heise.de)
- OpenAI deckt russische Einflusskampagne über ChatGPT auf
(the-decoder.de)
- Deepfake-Propaganda auf Telegram gegen ukrainische Politiker
(the-decoder.de)
- Princeton/UC-San-Diego-Studie zu "Skills" bei KI-Agenten
(the-decoder.de)
- Professor erwischt Studenten per Prompt-Injection beim KI-Schummeln
(t3n.de)