

Praxis-News

1. OpenAI kündigt Modell "Astra" mit "kritischer" Cyberfähigkeitsstufe an

OpenAI hat am 02.09.2026 das Modell Astra vorgestellt, das im eigenen Preparedness Framework erstmals die höchste Risikostufe "kritisch" für Cyberfähigkeiten erreicht. Im Benchmark ExploitBench erzielte Astra die volle Punktzahl und entdeckte unter 20 kürzlich offengelegten kritischen Schwachstellen zwei bislang unbekannte Zero-Day-Lücken eigenständig; zudem baute es eine komplette Browser-Kompromittierungskette inklusive Sandbox-Ausbruch. Laut OpenAI lehnt Astra 91,5% unangemessener Cyber-Anfragen ab (Vorgänger GPT-5.6 Sol: 59%), gleichzeitig wird die Überwachung schwieriger, da bei der genutzten "Recurrent Depth"-Architektur ein Teil des Denkprozesses nicht mehr in lesbarem Text stattfindet. Das Modell ist noch nicht im Normalbetrieb verfügbar, der Rollout ist zunächst auf Alpha-Tester begrenzt.

the-decoder.de

2. Google veröffentlicht Gemini Flash 3.8

Google hat am 02.09.2026 Gemini Flash 3.8 veröffentlicht, den Nachfolger des erst drei Wochen alten Gemini 3.7 Flash. Der Artificial-Analysis-Intelligence-Index-Score steigt von 56 auf 59, beim Software-Engineering-Benchmark DeepSWE v1.1 von 65,3% auf 73,7%. Einführungspreis: 0,75 US-Dollar je Million Input- bzw. 3,75 US-Dollar je Million Output-Token; trotz gleicher Preise liegt der Token-Verbrauch rund 40% höher, da das Modell mehr Reasoning-Schritte und iterative Tool-Aufrufe nutzt. Sofort verfügbar über Google AI Studio, AntigraVity, Android Studio, Gemini Enterprise und die Gemini-App.

the-decoder.de

3. Google macht Gemini-Videoanalyse agentisch: bis zu 88% weniger Token

Für Gemini 3.7 Flash, 3.6 Flash und 3.5 Flash-Lite entscheidet das Modell jetzt selbst, welche Videoabschnitte es sich mit welcher Geschwindigkeit und über welche Modalität ansieht, statt starr Frame für Frame zu verarbeiten. Das spart bis zu 88% Token und senkt die Kosten um 66% bei leicht gesteigerter Genauigkeit; neu erkennbar sind zudem Zustandsänderungen unter einer Sekunde sowie gezielte Szenensuche in stundenlangem Material. Verfügbar sofort über Gemini-API, Google AI Studio und die Enterprise-Agent-Plattform zu Standard-Token-Preisen.

the-decoder.de

4. World Labs stellt Weltmodell "Atlas" vor

World Labs (gegründet von Fei-Fei Li) hat mit Atlas ein von Grund auf trainiertes Omni-Modell vorgestellt, das Text, Bilder, Video und 3D-Daten verarbeitet und Eingaben an konkreten 3D-Positionen verankert. Es generiert bis zu eine Minute Video in 1440p, rekonstruiert reale Szenen aus 1 bis über 100 Eingabebildern und erzeugt explizite 3D-Ausgaben wie Punktwolken und 3D-Gaussian-Splats. Bei kameragesteuerter Generierung bevorzugten menschliche Bewerter Atlas in 75% der Fälle gegenüber MiniMax H3 und in 94% gegenüber Seedance 2.5. Aktuell nur als Early-Access-Programm für ausgewählte Partner verfügbar.

the-decoder.de

Tipps & Tricks

1. Agenten mit Link zur offiziellen Migrationsanleitung und prüfbarem Erfolgskriterium führen

Simon Willison hat sein Python-Plugin "llm-anthropic" migrieren lassen, indem er den Agenten anwies: "Upgrade to anthropic>=1 - read [Link zur MIGRATION.md] and get the tests passing." Der Kniff: ein direkter Link zur offiziellen Migrationsdokumentation plus ein maschinell prüfbares Erfolgskriterium (grüne Tests) statt einer vagen Anweisung. Ergebnis war ein funktionierender Pull Request inklusive mehrerer zusätzlicher Bugfixes. Übertragbar auf jede Migrations-/Upgrade-Aufgabe.

simonwillison.net

2. "Stop Making TUIs": eigene Werkzeuge als native GUI statt Terminal-Tool bauen

Thomas Ptacek argumentiert (eingeordnet von Simon Willison): Terminal-UIs waren historisch nur ein Pragmatismus-Kompromiss – da Coding-Agenten native GUIs inzwischen fast zum Nulltarif produzieren, lohnt sich der Bau richtiger GUIs auch für kleinste persönliche Tools. Konkreter Workflow: Vorlagen-App-Verzeichnis kopieren, Agent mit Zielbeschreibung arbeiten lassen, Computer-Use aktivieren, damit der Agent die App visuell selbst testet, über ein Makefile statt einer vollen IDE bauen. Konkrete Empfehlung: ein bestehendes CLI-Tool probeweise in eine native GUI umwandeln.

simonwillison.net

3. Wiederkehrende Aufgaben als dauerhafte Claude-Skill statt als Einzelprompt hinterlegen

t3n erklärt den Unterschied zwischen wiederholtem manuellem Prompten – bei dem Claude weder unternehmensinterne Standards noch den gewohnten Arbeitsprozess kennt – und dem Anlegen eines "Skill": einer dauerhaft hinterlegten Arbeitsanweisung mit Vorgaben, Kriterien und Beispielen. Als Beispiel nennt der Artikel monatliches Reporting, das so nicht mehr jedes Mal neu formuliert werden muss. Übertragbare Idee: für wiederkehrende, klar umrissene Aufgaben einen dauerhaften Skill statt eines Einzelprompts anzulegen.

t3n.de

Regulierung/Politik

1. US-Justizministerium stellt sich im NYT-Urheberrechtsstreit auf die Seite von OpenAI

Das US-Justizministerium unter der Trump-Regierung hat im Class-Action-Verfahren der New York Times gegen OpenAI und Microsoft ein "Statement of Interest" eingereicht und sich damit erstmals offiziell auf OpenAIs Seite gestellt. Die Regierung argumentiert, das Training von KI-Sprachmodellen mit urheberrechtlich geschütztem Material sei durch die Fair-Use-Doktrin gedeckt; als Begründung werden zudem nationale Sicherheitsinteressen angeführt. Die Position widerspricht einem früheren Bericht der US-Copyright-Amtsleiterin Shira Perlmutter, die nach Kritik am KI-Training entlassen worden war.

heise.de

Bedeutende Forschung

1. Systematisches Review: Patientenperspektive fehlt in der Mehrheit der Studien zu medizinischer KI

Ein systematisches Review im Fachjournal Nature Health wertete 330 Studien zur medizinischen KI aus. Nur in 3,9% der Studien wurde die Patientenperspektive bereits in der Design-/Entwicklungsphase einbezogen, in 89,4% erst in der späteren Validierungsphase. Nur 16,7% der Studien untersuchten das Vertrauen von Patienten in die KI-Systeme, nur 10,9% die Sicherheit aus Patientensicht; am häufigsten erfasst wurden Patientenzufriedenheit (70,6%) und wahrgenommener Nutzen (69,4%).

heise.de

Weitere gesichtete, aber ausgelassene Punkte

- BGH-Verhandlung Kneschke ./. LAION (heutige Verhandlung, Hintergrundartikel vor Verhandlungsbeginn – Ausgang folgt im nächsten Lauf)

(heise.de)