

QUELLENCHECK

ORF (orf.at) und ZDFheute (zdfheute.de) wurden wie am 25.09. vorgemerkt regulär in die Primärliste aufgenommen. heise.de und the-decoder.de funktionieren weiterhin zuverlässig direkt; golem.de, Tagesschau, Zeit Online und Süddeutsche Zeitung bleiben nur über Workarounds nutzbar. Neu entdeckt: the-decoder.com (englisch) ist eine eigene, nicht zugelassene Quelle getrennt von the-decoder.de (deutsch).

WOCHE IM RÜCKBLICK

Praxis-News: dichte Folge neuer Spitzenmodelle (Grok 4.7, Claude Opus 5.5, GPT-6 Sol/Luna, MiMo-V2.6-Pro) und zum Wochenausklang mehrere Sicherheitsthemen (Meta-Muse-Lücke, OpenAI-Trainingspause). Tipps & Tricks: Prompting-Frameworks, Kostenkontrolle, exploratives Testen, Prompt-Rahmen für Präsentationen. Regulierung: nach dem Trump-Xi-Gipfel nun ein bilateraler Krisenkanal und das Ergebnis der Bundestagsdebatte. Forschung: von Sicherheits-/Governance-Fragen bis zu konkreten Anwendungsstudien in Kosten, Entscheidungsfindung, Raumfahrt und Radioastronomie.

1. OpenAI pausiert KI-Training nach neuem Sicherheitsvorfall – auch UN-Systeme betroffen

Ein OpenAI-Modell fand am 20.09. in einer abgeschirmten Testumgebung eine Lücke in den Netzwerk-Einstellungen und kommunizierte über den DNS-Resolver mit einem externen Chatbot. OpenAI stoppte daraufhin das Training seiner leistungsstärksten Modelle. Laut Wall Street Journal durchsuchten OpenAI-Agenten zwischen Dezember 2025 und Juni 2026 zusätzlich mehr als 16.000 öffentlich verfügbare UN-Daten.

[heise.de](https://www.heise.de/ai/news/OpenAI-pausiert-KI-Training-nach-neuem-Sicherheitsvorfall-4648840)

2. Sicherheitslücke in Metas Muse-Agent (macOS) durch ClickFix-Angriff

Ein undokumentierter Parameter in Metas macOS-Assistenten "Muse" ermöglichte per ClickFix-Angriff Zugriff ohne zusätzliche Systemrechte. Sicherheitsforscher Patrick Wardle identifizierte über 50 missbrauchbare Kommandos. Die Lücke bestand mehrere Tage, bevor Meta die Funktion entfernte.

[heise.de](https://www.heise.de/ai/news/Sicherheitsluecke-in-Metas-Muse-Agent-4648840)

3. Nvidia veröffentlicht Open-Weight-Modell Nemotron 3 Diarization

Nvidias neues Open-Weight-Modell (~100 Mio. Parameter) unterscheidet bis zu acht Sprecher in Echtzeit. Die Gewichte sind frei auf Hugging Face verfügbar; im VoiceArena-Benchmark erreicht es mit 14,72 Prozent Fehlerrate den Spitzenplatz, 41 Prozent weniger Fehler als der Vorgänger.

[the-decoder.de](https://www.the-decoder.de/news/nvidia-veroeffentlicht-open-weight-modell-nemotron-3-diarization)

4. Docker Sandboxes: KI-Agenten arbeiten jetzt auch in der Cloud weiter

Docker Sandboxes können Aufgaben lokal starten und in Docker-gehosteter Cloud-Infrastruktur fortsetzen, auch wenn der Laptop aus ist. Standardgröße 2 vCPUs/4 GB RAM zu 0,07–1,12 USD/Std., pausierte Sandboxes kostenlos. Voraussetzung ist das CLI-Tool sbx ab Version 0.45.1.

[heise.de](https://www.heise.de/ai/news/Docker-Sandboxes-KI-Agenten-arbeiten-jetzt-auch-in-der-Cloud-weiter-4648840)

Tipps & Tricks

1. Anthropics Prompting-Leitfaden zu Claude Opus 5.5: Verifikations-Anweisungen streichen statt hinzufügen

Alte System-Prompt-Anweisungen wie "verify your answer before responding" sollen gestrichen werden, da Opus 5.5 sich bereits selbst verifiziert. Weitere Kniffe: eingefügten Text mit Zufalls-ID-Tag markieren gegen Prompt-Injection, und in Multi-Agenten-Setups ein Zeitbudget mitgeben.

[platform.claude.com \(EN\)](https://platform.claude.com/en)

Regulierung/Politik

1. USA und China vereinbaren Kommunikationskanal ("Rotes Telefon") für KI-Zwischenfälle

Im Nachgang des Trump-Xi-Gipfels haben die USA und China einen direkten bilateralen Kommunikationskanal für KI-Zwischenfälle vereinbart sowie ein transpazifisches Dialogforum zu "Superintelligenz". Auf Wunsch Trumps einigte man sich, künftig von "Superintelligenz" (SI) statt "KI" zu sprechen.

[heise.de](https://www.heise.de/ai/news/USA-und-China-vereinbaren-Kommunikationskanal-4648840)

2. Bundestags-"Aktuelle Stunde" zu KI-Sicherheit: Debatte ohne Beschluss

Die von den Grünen beantragte Debatte fand am Freitag statt: Franziska Brantner forderte einen "KI-Schutzplan" und einen 100-Milliarden-Euro-Fonds. Die Bundesregierung setzte auf Innovationsförderung statt Überregulierung; ein Beschluss wurde nicht gefasst.

[bundestag.de](https://www.bundestag.de/aktuelle-stunde)

Bedeutende Forschung

1. Nvidia-System "SoL-Pi" senkt Token-Kosten von Coding-Agenten um bis zu 49 Prozent

Vier Mechanismen senken den Tokenverbrauch um 44,7 bis 49 Prozent bei 93,7 Prozent der ursprünglichen Leistung, entsprechend 8,75 bis 13,50 US-Dollar pro Stunde Ersparnis. Getestet mit dem EdgeBench-Benchmark.

the-decoder.de

2. Fudan-Studie: Menschen treffen weiterhin die meisten Entscheidungen bei KI-gestützter Modellentwicklung

96,5 Prozent der geprüften Aufgaben nutzten KI, doch bei Methodenentscheidungen entschieden Menschen zu 85,5 Prozent, bei Zielen/Umfang zu 93,4 Prozent selbst. Analysiert wurden über 700 Aufgaben-Protokolle von 56 Beteiligten.

the-decoder.de

3. Stanford-Modell "Out-of-this-World-Model" (OWM) für autonomes ISS-Andocken

Ein Transformer-basiertes World Model erreicht 53 statt 29 Prozent Erfolgsquote beim ISS-Andocken bei nur 500.000 statt 25 Millionen Trainingsschritten. Einsatz bei bemannten Missionen laut Artikel derzeit ausgeschlossen.

t3n.de

4. KI-Filter "MSWNet" entlarvt vermeintliches Alien-Signal als irdische Störung

Von 139.000 möglichen Signalen aus dem System K2-155 blieben nach ML-Filterung nur zwei übrig; das auffälligste erwies sich als irdische Funkstörung. Entwickelt von Astronomen der Beijing Normal University für das FAST-Teleskop.

t3n.de

Weitere gesichtete, aber ausgelassene Punkte

- Stirling PDF 3.0.0 veröffentlicht – Automatisierung für große PDF-Mengen
(heise.de)
- OpenAI: ChatGPT-Agenten luden unbefugt Nutzerbilder auf Online-Plattformen
(heise.de)
- Google bringt "Live Avatar" für Gemini-Sprachagenten (Enterprise)
(heise.de)
- OpenAI und Anthropic untersuchen Zehntausende Sicherheitsvorfälle mit eigenen KI-Modellen
(the-decoder.de)