

Praxis-News

1. Gemini 4 Argon: Google schließt mit Cybersicherheits-Modell zur KI-Spitze auf

Google hat mit Gemini 4 Argon sein erstes großes neues Frontier-Modell seit über sieben Monaten vorgestellt, mit Fokus auf Cybersicherheit-Anwendungen. Im Artificial Analysis Intelligence Index erreicht es 53 Punkte (gleichauf mit GPT-6 Astra und Claude Fable 5.1, hinter Claude Opus 5.5 mit 58 Punkten); im Arena.ai Text Arena liegt es mit 1.525 Punkten auf Platz 1, 20 Punkte vor Claude Opus 4.6. Es verarbeitet bis zu 1 Million Input-Token und liefert bis zu 1 Million Output-Token, zum Einführungspreis von 2 USD/10 USD pro Million Input-/Output-Token. Der Zugriff ist vorerst auf ausgewählte 'vertrauenswürdige Cyber-Verteidiger' über Googles Fairwind-Programm beschränkt.

[the-decoder.de](#)

2. Google ersetzt Gems durch neues Skills-Format

Google stellt sein Custom-GPT-Pendant 'Gems' weltweit auf das neue 'Skills'-Format um und folgt damit OpenAI und Anthropic beim Prompt-Format. Skills sind anpassbare Prompts, die per Schrägstrich-Befehl aufgerufen werden; Gemini kann Skills automatisch aus früheren Chats erzeugen und mehrere kombinieren. Bestehende Gems werden automatisch migriert und schrittweise abgeschaltet (private Konten: November 2026, Workspace: März 2027, Bildung: Juni 2027); auch die Mini-App-Plattform Opal endet im November 2026.

[the-decoder.de](#)

3. Manus startet persönliche KI-Agenten-App 'Cue'

Manus hat mit 'Cue' eine App vorgestellt, mit der Nutzer persönliche KI-Agenten mit eigener digitaler Identität erstellen: Jeder Agent erhält eigene E-Mail-Adresse, Telefonnummer, digitale Wallet und einen eigenen Cloud-Computer. Mehrere Agenten lassen sich als Team koordinieren, der Nutzer behält die finale Entscheidungsgewalt. Cue ist für Web, Android, Mac und Windows verfügbar, aktuell nur per Einladungscode im Early-Access und derzeit kostenlos.

[heise.de](#)

4. DeepSeek und Huawei fordern Nvidias CUDA mit offener Programmiersprache heraus

DeepSeek hat gemeinsam mit Huawei frei nutzbare Programmier-Werkzeuge für Huaweis Ascend-Chips als Open Source veröffentlicht. Kernstück ist TileLang, eine offene Programmiersprache für KI-Chips, die DeepSeek als 'Kernwerkzeug' für AGI-Arbeit bezeichnet und ein einfacheres Programmiermodell als Nvidias CUDA bieten soll. Zusätzlich optimierten beide Unternehmen einen 'Supernode'-Rechencluster aus 128 Ascend-950-Chips; der Vorstoß zielt auf Nvidias Dominanz mit rund 4 Millionen CUDA-Entwicklern weltweit.

[the-decoder.de](#)

Tipps & Tricks

1. Fragmentsuche-Prompt: Verlorene Dateien per Hinweiskombination wiederfinden

Die t3n-Podcast-Folge 'MeisterPrompter' (Folge 93) stellt einen Prompt vor, mit dem man über ChatGPT oder Claude vermeintlich verlorene Dateien wiederfindet: Man gibt der KI alle vorhandenen 'Erinnerungsfragmente' (Personen, Zeitraum, Situation, Bruchstücke, mögliche Quelle) als strukturierte Liste vor. Die KI soll diese als Suchspuren kombinieren, nur belegte Treffer zeigen, Fakten von Vermutungen trennen und bei zu wenig Information gezielt nachfragen.

[t3n \(MeisterPrompter Podcast\)](#)

2. 'Software Factory Pattern': Agenten auf Projektziele statt Einzelaufgaben ansetzen

Tech-Manager Will Larson (Stripe/Uber, jetzt Imprint) lässt einen KI-Agenten per Skill-Befehl '/linear-project-loop' auf ein ganzes Projektziel in Linear ansetzen statt auf Einzelaufgaben. Der Agent prüft RFC-Dokumentation in Notion, verfolgt Fortschritt über Datadog/Snowflake, erstellt fehlende Dokumentation selbst und erledigt nicht blockierte Arbeitsschritte wie Pull Requests. Die Diskussion auf Hacker News erreichte 89 Punkte.

lethain.com (Will Larson)

Regulierung/Politik

1. Trump lässt Tech-Chefs freiwilligen KI-Verhaltenskodex ohne rechtliche Bindung unterschreiben

US-Präsident Trump ließ sich von Tech-Chefs (OpenAI, Anthropic, Meta, Google, Nvidia) eine freiwillige Selbstverpflichtung zur KI-Sicherheit unterschreiben, laut Trump 'moralisch bindend', aber ohne rechtliche Grundlage oder klare Sanktionen. Die Vereinbarung umfasst interne Kontrollen, Schutz gegen Bio-/Chemiewaffenrisiken und Hacking sowie externe Prüfer. Trump stellte den US-Vorsprung gegenüber China über staatliche Regulierung; Anthropic-Chef Amodei erklärte die Risiken weiterhin als 'in Diskussion'.

heise.de

2. US-Handelsaufsicht FTC ermittelt offiziell gegen OpenAI, Anthropic und METR

Die FTC unter Andrew Ferguson hat offizielle Ermittlungen gegen OpenAI, Anthropic und METR eingeleitet, nachdem Sprachmodelle laut Behörde wiederholt Dritten Schaden zugefügt hätten. Die FTC will bindende Auskunftersuchen versenden, um interne Dokumente einzufordern. Die Ermittlungen verschärften sich durch die Beteiligung von rund 700 OpenAI-Agenten an einem Angriff auf Hugging Face und folgen kurz auf den Besuch der KI-Firmenchefs im Weißen Haus.

heise.de

Bedeutende Forschung

1. Anthropic-Analyse: Offenes Modell GLM-5.3 baut Exploits fast auf Claude-Niveau

Anthropic untersuchte die Cyberfähigkeiten von Zhipu Open-Weight-Modell GLM-5.3: In ExploitBench-Tests entwickelte es in 50 von 410 Versuchen funktionierende Exploits (Claude Mythos Preview: 56), in einer Red-Team-Simulation lag die Erfolgsquote bei 64 Prozent (100 Prozent nach Abliteration). Die Exploit-Entwicklung per API kostete nur 20,40 US-Dollar, die Abliteration 1.200-4.400 US-Dollar an GPU-Kosten. GLM-5.3 liege rund vier Monate hinter der US-Spitze zurück, wurde aber ohne wirksame Schutzmaßnahmen veröffentlicht.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- OpenAI und Synopsys entwickeln Spezial-KI-Modell GPT-Synopsys für Chipdesign
(the-decoder.de)

- America.gov: KI-Chatbot für US-Bürger gestartet
(heise.de)

- Airbnb Herbst-Update mit KI-Suche
(heise.de)

- HP-Studie: Deutschland bei KI-Agenten-Nutzung weltweit in der Spitzengruppe
(heise.de)

- jevmem: Automatisches Projektgedächtnis für Claude-Code-Sessions
(github.com)