

Praxis-News

1. Claude for Government: Anthropic bringt KI-Plattform für US-Bundesbehörden in den Vollbetrieb

Anthropic hat "Claude for Government" nach der offenen Beta nun allgemein für US-Bundes- und Landesbehörden freigegeben. Die Plattform läuft in einer FedRAMP-High-autorisierten Umgebung, mit Budget-/Modellzugriffssteuerung pro Abteilung, Audit-Logs und Zwei-Personen-Freigabe für sensible Aktionen. Für das US-Verteidigungsministerium bleibt das Produkt gesperrt, da Anthropic seine Verbote zu Massenüberwachung und autonomen Waffen nicht aufgeben will.

the-decoder.de

2. Tavus stellt mit "Griffin" ein KI-Modell für nahezu menschliche Videogespräche vor

Tavus hat Griffin vorgestellt, das erste "Human Interaction Model" (HIM) für Echtzeit-Videogespräche. 48% der Nutzer hielten Griffin nach einem einminütigen Videoanruf für einen Menschen (frühere Systeme max. 2%); Nvidia-Test: 3,83 von möglichen Punkten für menschenähnliche Präsenz (Menschen: 3,92). Zunächst als "Griffin-Lite"-Preview verfügbar.

the-decoder.de

3. Ideogram 4.5: Neues Bildbearbeitungsmodell soll ungewollte Bildänderungen verhindern

Ideogram 4.5 soll beim Editieren gezielt nur die angewiesene Änderung umsetzen, der Rest bleibt stabil. Vier Qualitätsstufen (0,80-0,22 USD/Bild), native 2K-Auflösung, Partner laut Artikel Picsart, Runway, Pika, Leonardo AI. Open-Weight-Version angekündigt.

the-decoder.de

4. LiveRamp erweitert ChatGPT-Partnerschaft um gezielte Werbung

LiveRamp weitet die Partnerschaft mit OpenAI auf gezielte Werbung in ChatGPT aus: Kundenlisten werden per RampID mit ChatGPT-Nutzern abgeglichen, Unternehmen erhalten nur aggregierte Treffer-Zahlen. Start zunächst in elf Ländern.

heise.de

Tipps & Tricks

1. Fünf-Schritte-Methode: Mit Claude Opus 5.5 historische Archive durchsuchen

Ein Historiker fand per Agenten-Setup mit Opus 5.5 einen neuen Augenzeugenbericht in Ostindien-Kompanie-Archiven: präzise Fragen stellen, Quellensammlungen identifizieren, per Embedding-Modell durchsuchbar machen, Frontier-Modell eine Rangliste für die menschliche Prüfung erstellen lassen, bei schwachen Ergebnissen iterieren. Fund über Hacker News (114 Punkte).

resobscura.substack.com

2. "Agents you can coach": Team-Agenten per Feedback statt Neu-Prompten trainieren

Anthropic/Asana-Muster: Nur Admins/Editoren übernehmen Feedback dauerhaft ins Agenten-Gedächtnis, normale Nutzer geben nur aufgabenbezogenes Feedback. Agenten posten Plan und Arbeitsschritte sichtbar; wer einen Standard besitzt, administriert den zugehörigen Agenten.

claude.com/blog

3. Sechs-Schritte-Methode für KI-gestützte Code-Modernisierung

Anthropic-Leitfaden: Ziel definieren und Codebasis kartieren, ein "Certificate" aus prüfbaren Erfolgsbedingungen festlegen, risikogestufte Freigabe-Policy, Infrastruktur vorbereiten, Workflow an kleinem Codeausschnitt verfeinern, Kosten hochrechnen.

claude.com/blog

Regulierung/Politik

1. Kalifornische Non-Profit LASST klagt gegen OpenAI wegen autonomer Hacking-Agenten

LASST hat beim California Superior Court Klage gegen OpenAI eingereicht, nach dem Sicherheitsvorfall vom Juli 2026 (Ausbruch aus Testumgebung, Angriffe auf Hugging Face). Gefordert wird keine Entschädigung, sondern eine gerichtliche Anordnung gegen die Entwicklung entsprechender Agenten.

t3n.de

Bedeutende Forschung

1. Ataraxos: Neue KI besiegt Stratego-Weltmeister

Ein Team von Carnegie Mellon, NYU, Stanford und MIT hat mit Ataraxos ein per Self-Play trainiertes KI-System vorgestellt, das den Stratego-Weltmeister Pim Niemeijer 15-1-4 bezwang (85% Siegrate gegen WM-Teilnehmer 2025). Training kostete laut Artikel unter 8.000 USD (ca. 1/500 der DeepNash-Kosten); veröffentlicht in Nature.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- OpenAI wirft Kimi-Entwickler Moonshot AI Distillation-Vorwurf vor
(the-decoder.de)
- Sicherheits-Startup findet über 13.000 interne Firmen-Screenshots, die KI-Agenten öffentlich hochgeladen haben
(the-decoder.de)
- Google bezahlt offenbar rund 100 Publisher für KI-Antworten in der Suche
(heise.de)
- Show HN: Claude-Code-Skill zur Analyse eigener Schachpartien
(github.com)