

Praxis-News

1. Claude Haiku 5.5 (Anthropic) – schnelleres, günstigeres Haiku-Modell

Anthropic hat Claude Haiku 5.5 veröffentlicht, laut eigenen Angaben das bisher schnellste, günstigste und fähigste Haiku-Modell, gedacht für hochvolumige Aufgaben wie Zusammenfassungen, Klassifikation und als Coding-Subagent neben Sonnet/Opus 5.5. Es ist ab sofort über die Claude-Plattform-API sowie AWS Bedrock, Google Cloud und Microsoft Azure verfügbar und kostet laut Anthropic rund 90 Prozent weniger als Haiku 4.5 (0,10 \$ Input / 0,50 \$ Output pro Million Token bis 100.000 Kontext); erstmals bietet ein Haiku-Modell eine einstellbare „Effort“-Stufe von Low bis Max. Auf Anthropics eigenen Benchmarks übertrifft es Haiku 4.5 und teils auch GPT-6 Luna, bleibt aber hinter Sonnet 5.5 zurück.

anthropic.com

2. Microsoft stellt Agentic Windows Desktop und neue KI-Hardware vor

Microsoft hat die „Microsoft Execution Containers“ (MXC) als Sandbox für KI-Agenten allgemein verfügbar gemacht – Agenten laufen künftig unter eigenen Benutzerkonten mit eigenen Zugriffsrechten. Microsoft, Nvidia und DeepSeek zeigten zudem stark quantisierte Lokal-Modelle für die neue Nvidia-RTX-Spark-Hardware. Copilot erhält drei neue Fähigkeiten (Copilot Home, Copilot Code, Autopilot), GitHub Copilot soll über HydraFusion auch lokale Modelle nutzen können, und Windows ML unterstützt künftig zusätzlich llama.cpp.

heise.de

3. Googles KI-Fake-Detektor SynthID jetzt für fast alle zugänglich

Der SynthID-Detector-Dienst von Google ist jetzt für alle Nutzer mit Google-, Apple- oder ChatGPT-Konto geöffnet. Das Tool erkennt unsichtbare SynthID-Wasserzeichen in Bildern, Videos und Audio – nicht nur von Google selbst, sondern auch von den Partnern OpenAI, Nvidia und Kakao. Die Kennzeichnung lässt sich zusätzlich direkt in Google Search, der Gemini-App und in Chrome auslesen.

heise.de

4. Ollama nutzt auf dem Mac künftig standardmäßig MLX statt llama.cpp

Ab Version 0.40.0 setzt Ollama auf Apple-Silicon-Macs standardmäßig auf Apples MLX-Framework statt auf llama.cpp – allerdings bislang nur für unterstützte Modellarchitekturen wie Gemma 4, Qwen 3.5/3.6 und EmbeddingGemma 2. Befehle wie „ollama pull“ und „ollama run“ sowie die lokale API bleiben unverändert.

heise.de

Tipps & Tricks

1. Erst Datenformat vom Modell entwerfen lassen, dann das passende Tool bauen

Statt eine KI direkt eine fertige Anwendung bauen zu lassen, lässt man sie zunächst ein eigenes, einfaches Datenformat für den Inhalt entwerfen – und erst danach die Anwendung, die genau dieses Format nutzt. Ein greifbarer Qualitätsmaßstab (z. B. ein Referenzbeispiel) gibt dem Modell ein klares Ziel. Die Methode ist auf andere kreative/strukturelle Aufgaben übertragbar: Modellierung zuerst, Anwendung danach.

simonwillison.net

2. Coding-Agenten in zwei Phasen führen: erst Ist-Zustand, dann Aufwand abschätzen

Statt einem Coding-Agenten sofort eine umfassende Aufgabe zu stellen, lohnt sich ein zweistufiger Prompt-Ansatz: Phase 1 analysiert nur den aktuellen Stand, Phase 2 schätzt ab, was für neue Ziele nötig wäre. Diese Trennung verhindert voreiliges Programmieren ohne Verständnis des Bestands. In einem Testlauf mit Claude Opus 5.5 führte dies zu 42 Commits und fast vollständiger Abdeckung einer WASM-Spezifikation.

simonwillison.net

3. Reasoning-Modus gezielt für Rechen- und Zählaufgaben aktivieren

Bei strukturiertem Schritt-für-Schritt-Rechnen lohnt es sich, den Reasoning-/Thinking-Modus bewusst einzuschalten statt der Standardeinstellung zu vertrauen. Ein lokales Qwen3.8-27B-Modell löste ohne Reasoning nur 23,6 % der Aufgaben richtig, mit aktiviertem Reasoning rund 98,8 %. Der Kniff ist auf vergleichbare Logik-/Rechenaufgaben übertragbar.

simonwillison.net

4. Bei Qualitätsproblemen eine Reasoning-Stufe tiefer testen statt höher

Mehr Denkbudget ist nicht automatisch besser: Im „max“-Modus kann ein Modell sein gesamtes Token-Budget aufbrauchen, ohne ein Ergebnis zu liefern. Der Kniff: bei Fehlschlägen eine Stufe herunterschalten statt mehr Budget nachzuschießen. Claude Sonnet 5.5 scheiterte im „max“-Modus nach 128.000 Denk-Tokens, lieferte im „xhigh“-Modus aber in 41 Sekunden ein brauchbares Resultat.

simonwillison.net

Regulierung/Politik

1. Hinton fordert FDA-ähnliche Zulassungspflicht für KI-Modelle

Nobelpreisträger Geoffrey Hinton hat gefordert, KI-Modelle vor Markteinführung ähnlich wie Medikamente durch eine Zulassungsbehörde prüfen zu lassen – analog zum rund eine Milliarde US-Dollar teuren FDA-Prozess. Er verweist auf ein Ende September 2026 erschienenenes Paper (mit Yoshua Bengio u. a.), das vor Kontrollverlust über superintelligente Systeme warnt und laut Hinton nur ein- bis zweijähriges Zeitfenster für Gegenmaßnahmen sieht. Ein früherer Forscher-Appell im Juli 2026 zeigte wenig Wirkung; die Trump-Administration setzt weiter auf Selbstregulierung.

t3n.de

Bedeutende Forschung

1. Studie stuft ChatGPT for Teens als „inakzeptables Risiko“ ein

Das Common Sense Media Youth AI Safety Institute hat ChatGPT for Teens anhand von über 4.000 Testeingaben geprüft und stuft den Dienst für Minderjährige als „inakzeptables Risiko“ ein. Gespräche über Suizid, Selbstverletzung oder Essstörungen lösten keine Eltern-Benachrichtigung aus, in über einem Viertel nötiger Fälle fehlte die Weitervermittlung an professionelle Hilfe. Als 13-Jährige nachgemeldete Erwachsenen-Accounts wechselten nicht in den Teenager-Modus; OpenAI nannte die Testmethodik unpraktisch.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- Anthropic bündelt Cyberprogramme und führt drei Zugriffsstufen ein
(heise.de)
- Konkurrenz zu Visa: Meta und Sierra stellen neues Personal Agent Protocol vor
(heise.de)
- GitHub ReviewBench: neuer Benchmark für KI-gestützte Code-Reviews
(heise.de)
- „KI im Kleiderschrank“: Mit diesem Prompt werden ChatGPT und Claude zu Modeberatern
(t3n.de)
- „Mein Irrtum“: Warum die Grenzen von LLMs weiter entfernt sind, als ich dachte
(golem.de)