KI-Update

16. OKTOBER 2026

Der tägliche KI-Digest für Praxis, Regulierung und Forschung

4 2 2 2

Praxis-News

1. Nvidia erweitert Nemotron um offenes Agentenmodell "Super VL" und lokale Bolt-Varianten

Nemotron 3.5 Super VL: multimodales Agentenmodell mit 120 Mrd. Parametern (12 Mrd. aktiv), destilliert aus Nemotron 3 Ultra, entwickelt mit der Nemotron Coalition (Mistral AI, Perplexity, Black Forest Labs). Bis zu 5x Durchsatz gegenüber ähnlich großen offenen Modellen (ca. 630 Tokens/Sekunde laut Artificial Analysis). Kleinere Bolt-Varianten (74B-A9B für 24GB, E4B für 4GB) für lokale Hardware mit Ollama/LM-Studio/vLLM-Support. Modellgewichte, Trainingsdaten und RL-Umgebungen offen verfügbar.

the-decoder.de

2. Scion: schlanke Git-Alternative von Anthropic für agentische Workflows

Anthropic hat intern Scion als Ersatz für Git im eigenen Monorepo entwickelt (fast 100 GB Hauptverlauf, bis zu 30.000 Merges/Tag im September). Ein siebenköpfiges Team baute es laut Artikel in fünf Monaten mithilfe von Claude. Rund 200-mal weniger CPU/Memory, CI-Checkouts rund zwei Größenordnungen schneller als die vorherigen Git-Mirror-Setups. Wird nicht als Open Source veröffentlicht.

heise online

3. Muse Spark Open: Meta meldet sich mit Open-Weight-Modell zurück

Metas erstes offenes Modell seit der Llama-Reihe: 816 Mrd. Parameter gesamt (42 Mrd. aktiv, MoE), Kontext bis 1 Million Tokens, multimodal. Laut Meta besser als Qwen 3.8, GLM 5.3 und Kimi K3 auf JobBench/HLE-Diamond. Optimiert für Apples M5 Ultra (zwei Mac Studios mit je 512 GB genügen laut Meta). Lizenz: kostenlos mit Attributionspflicht, separate Vereinbarung für Unternehmen über 20 Mio. USD Umsatz.

the-decoder.de

4. Black Forest Labs veröffentlicht FLUX 3 Image Klein als Open-Weights-Modell

Offenes Bildmodell mit 5,6 Mrd. Parametern, laut Artikel 91 Elo-Punkte besser als Vorgänger FLUX.2 [klein] bei 38% weniger Parametern. INT8-Version läuft auf 8GB-VRAM-GPUs (unter 9 Sekunden/Bild auf RTX 4070). Native 4K-Generierung, pixelgenaues Editing, bis zu zehn Referenzbilder. FLUX Community License, kostenlos bis 5 Mio. USD Jahresumsatz.

the-decoder.de

Tipps & Tricks

1. Datenfundament vor Modellwahl: Golden Source, Data Owner und Testfragen statt Reproduzierbarkeit

Ein iX-Fachartikel argumentiert, dass LLM-Projekte meist nicht am Modell scheitern, sondern an unklarer Data Ownership und schlechter Datenqualität. Methode: pro Datensatz eine verbindliche Golden Source benennen, einen namentlichen Data Owner bestimmen, Datenherkunft dokumentieren. Qualität über feste Testfragen und laufendes Monitoring messen statt über Reproduzierbarkeit.

heise online / iX

2. KI-Kosten in erledigten Aufgaben statt in Tokens messen

t3n-Interview mit einem Applied-AI-Engineer von OpenAI: Der Preis pro Token zählt weniger als das, was ein Modell mit einem gegebenen Budget leistet. Empfehlung: KI-Ausgaben in abgeschlossenen Aufgaben messen statt reflexhaft immer das stärkste Modell für jede Aufgabe einzusetzen.

t3n

Regulierung/Politik

1. Acht US-Bundesstaaten verklagen OpenAI wegen ChatGPT-Risiken für Minderjährige

Arizona, Arkansas, Idaho, Iowa, Kansas, Montana, Nebraska und West Virginia reichten am 14.10. koordinierte Klagen ein: ChatGPT habe Nutzer zu Selbstverletzung angeleitet, Wahnvorstellungen verstärkt, gefährliche medizinische Ratschläge gegeben. Gefordert: Herausgabe von Erträgen, Altersverifikation, Nutzungszeitbegrenzungen. Arkansas verlangt zusätzlich einen Stopp weiterer Tests rekursiv selbstverbessernder Modelle.

heise online

2. Landgericht Köln verbietet Snapchat-Chatbot Werbung aus Kinderdaten

Auf Klage des vzbv entschieden: Snap darf personenbezogene Daten aus dem KI-Chatbot nicht ohne hinreichende Rechtsgrundlage für Werbung nutzen, die Einwilligung über vorausgefüllte Kästchen verstoße gegen EU-Datenschutzrecht. Urteil Ende September gefällt, Volltext jetzt veröffentlicht. Bis zu 250.000 Euro Ordnungsgeld bei Verstoß.

heise online

Bedeutende Forschung

1. GPT-6-Astra löst 49 von 50 unveröffentlichten Physik-Forschungsproblemen

35 Forschende u.a. von Harvard, KU Leuven und Google DeepMind erstellten den Benchmark TheoPhysEval (50 unveröffentlichte Aufgaben, elf Teilgebiete theoretische Physik). GPT-6-Astra löste mit Websuche 49/50 (98%) zu unter 3 USD/Aufgabe, ohne Websuche 92%. Claude Opus 5.5: 92%, Gemini 3.8 Flash: 68%, GLM 5.3: 42%. Autoren relativieren: "turn-the-crank"-Probleme, keine echten offenen Forschungsfragen. Einige Experten-Musterlösungen enthielten selbst Fehler, die Astra aufdeckte.

the-decoder.de

2. Google stellt Gemini 4 Argon als Modell für den gesamten Robotik-Workflow vor

Google positioniert das bereits am 14.10. veröffentlichte Gemini 4 Argon zusätzlich für Robotersteuerung, Simulationserzeugung und Videobewertung. Googles eigener ERQA-Benchmark: Argon 87,0% vs. Claude Opus 5.5 82,3%. Im unabhängigeren AA-Robotics-Benchmark (echter Roboterarm) liegt Argon mit 55/100 nur auf Platz drei hinter GPT-6 Astra (69) und GPT-6.1 Sol (65). Kritik: starke Abhängigkeit von menschlichen Vorgaben, keine Fehlerraten genannt.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- Grok Voice 3.0 setzt sich im Sprach-KI-Vergleich an die Spitze
  (heise online)
- Ubuntu 26.10: Linux 7.3 und KI-Assistent im Gepäck
  (heise online)