KI-Update

04. NOVEMBER 2026

Der tägliche KI-Digest für Praxis, Regulierung und Forschung

4 3 3 3

Praxis-News

1. Anthropic macht langlaufende KI-Agenten mit "Message Threads" bis zu 35 Prozent schneller

Die neue Beta-Funktion der Claude-Plattform überträgt bei jeder Anfrage nur noch neu hinzugekommene Inhalte statt des gesamten Gesprächsverlaufs. Laut Anthropic sinkt dadurch die Zeit bis zum ersten Token bei Anfragen mit 500.000 bis 1 Million Tokens um rund 35 Prozent; der Thread bleibt verschlüsselt im Speicher und läuft nach 5 Minuten Inaktivität ab. Verfügbar auf der Claude-Plattform sowie über AWS, Microsoft Foundry und Google Cloud.

the-decoder.de

2. OpenAI vervierfacht Bug-Bounty-Prämien und startet neuen Security Sprint

Kritische Schwachstellen bringen jetzt bis zu 30.000 Dollar, außergewöhnliche Funde bis zu 100.000 Dollar, mit allen Boni maximal rund 172.000 Dollar. Neu: ein fünfstufiges Treue-Programm und befristete Kampagnen für neue Features. Zusätzlich testet die Sicherheitsfirma Cathedral gemeinsam mit OpenAI-Teams interne Systeme in einem "Security Sprint".

the-decoder.de

3. Anthropic verbietet Claude Code das Nachbauen bestehender Videospiele

Nach einer Welle KI-gestützter Klone (u.a. Hunderte Browser-Ports von Halo und GTA: Vice City) verhindern laut Anthropic-Mitarbeiter Addy Osmani zwei zusätzliche Sätze im Systemprompt von Claude Code das Nachbauen bestehender Spiele. Eigene Spiele und Projekte mit selbst erstellten Assets sollen weiter funktionieren.

the-decoder.de

4. Anthropic warnt im Börsenprospekt vor möglicher KI-Selbstbeschleunigung

Anthropic hält es für denkbar, bald eine "kritische Schwelle" zu erreichen, ab der KI-gestützte Forschung neue Modelle mindestens doppelt so schnell entwickelt wie ohne KI. Laut einer internen September-Studie erledigt Claude bereits bei rund einem Viertel der F&E-Arbeit selbstständig den Großteil der Aufgaben, aber unter menschlicher Aufsicht.

heise.de

Tipps & Tricks

1. Fünf bis sechs Coding-Agenten parallel: eigene Git-Worktrees plus Draft-PR-Review

Ein vielbeachteter Blogpost (über Hacker News, 127 Punkte) beschreibt, wie man 5-6 Coding-Agenten parallel laufen lässt: Jeder Agent bekommt per Git-Worktree eine eigene Codekopie und eine klar umrissene Einzelaufgabe. Review erfolgt über "Draft PRs" mit Fokus auf Architektur und wiederkehrende Fehlermuster als feste Review-Regeln.

ben.stolovitz.com (via Hacker News)

2. KI als sokratischer Tutor: aktive Rückfragen statt reiner Zusammenfassung erzwingen

Statt sich Ergebnisse nur zusammenfassen zu lassen, lässt sich Claude per Skill gezielt Rückfragen stellen, um selbst Lösungsansätze zu erarbeiten, und bei langen Code-Reviews mit Quizfragen zum eigenen Verständnis befragen. Modelle neigen ohne expliziten Auftrag zum bloßen Zusammenfassen statt zum aktiven Lehren.

ben.stolovitz.com (via Hacker News)

3. Skills für KI: wann sich wiederverwendbare Arbeitsanleitungen lohnen

Folge 98 des t3n-Podcasts MeisterPrompter erklärt "Skills" - wiederverwendbare Arbeitsanleitungen für ChatGPT, Claude und Gemini. Die Hosts raten, Skills nur für wiederkehrende Aufgaben mit festen Kriterien anzulegen statt wahllos, und sie bei Bedarf weiterzuentwickeln.

t3n MeisterPrompter

Regulierung/Politik

1. EuGH-Generalanwalt: KI-Chatbots können Urheberrecht von Verlagen verletzen

Im ersten EuGH-Verfahren zu generativer KI hält Generalanwalt Maciej Szpunar fest: Entscheidend ist, ob eine Antwort die Ausdrucksform eines Artikels so erkennbar wiederverwendet, dass Lesende den Originalartikel nicht mehr öffnen müssen. Das KI-Training selbst sei nach der EU-Text-and-Data-Mining-Ausnahme "frei zulässig".

heise.de

2. Indien plant zentrale Datenplattform statt Datensammlung durch KI-Anbieter

Indiens IT-Ministerium schlägt im Rahmen der "Data Empowerment and Protection Architecture" eine zentrale "Data Exchange Platform" vor: Datenquellen speichern anonymisierte Daten dort, KI-Unternehmen erhalten Zugriff nach den Bedingungen der Plattform statt eigener Sammlung.

heise.de

3. Digitalgipfel 2026: Bundesregierung streitet über KI-Folgen für den Arbeitsmarkt

Digitalminister Karsten Wildberger (CDU) fordert mehr unternehmerische Ambition; Arbeitsminister Alexander Schweitzer (SPD) will eine Phase erhöhter Arbeitslosigkeit verhindern. Arbeitsmarktforscher Enzo Weber (IAB) warnt vor einer Flucht ins Handwerk aus KI-Angst.

heise.de

Bedeutende Forschung

1. Mathematiker-Verband kritisiert Flut von KI-generierten Beweisversuchen bei OpenAI

Nach über 700 von OpenAI veröffentlichten Manuskripten zu mathematischen Problemen kritisiert die Deutsche Mathematiker-Vereinigung die Menge als Machtdemonstration statt Beleg wissenschaftlicher Kompetenz: KI ziele auf schnelle Lösungen statt neue Methoden, Menschen könnten die Fülle kaum prüfen.

t3n.de

2. PEARL: Neue Trainingsmethode soll unerwünschtes KI-Verhalten dauerhaft unterdrücken

Ein Preprint stellt mit "PEARL" eine GRPO-Variante vor, erprobt an absichtlich fehlausgerichteten Test-Modellen. Getestet an Qwen3-4B und GPT-OSS-20B unterdrückt PEARL das Fehlverhalten sofort bei erhaltener Aufgabengenauigkeit - dauerhaft auch nach weiterem Fine-Tuning.

arxiv.org

3. Studie: Austausch des LLM-Judges kann Modell-Rangfolgen komplett verändern

Fünf LLM-Judges dreier Anbieter bewerteten 4.000 Chatbot-Arena-Duelle gegen menschliche Abstimmungen: Die Übereinstimmung mit Menschen ist gering (medianes Cohen's Kappa 0,22), die Rangkorrelation schwankt zwischen 0,17 und 0,89. Ein Wechsel des Judge-Modells kann die gemessene Rangfolge verändern.

arxiv.org

Weitere gesichtete, aber ausgelassene Punkte

- KI-Agenten steuern erstmals ein Radioteleskop bei der SETI-Suche (Allen Telescope Array)
  (the-decoder.de)
- 27-Jähriger saniert Cisco-eigenen Code per KI-Agenten
  (heise.de)
- Goldman Sachs schränkt KI-Coding-Tool-Zugriff für Trader/Banker wieder ein
  (the-decoder.de)

- Qwen 3.8 27B interpretiert rohe Modellgewichte eines neuronalen Netzes (Experiment)
  (simonwillison.net)