KI-Update

05. NOVEMBER 2026

Der tägliche KI-Digest: Praxis-News, Tipps & Tricks, Regulierung und Forschung

4 - - 2

Praxis-News

1. Anthropic stellt FlashProve vor: kryptographischer Nachweis, welches KI-Modell geantwortet hat

Der Open-Source-Forschungsprototyp beweist per Zero-Knowledge-Verfahren kryptographisch, dass eine Antwort tatsächlich von den Gewichten des angegebenen Modells berechnet wurde. Im Test mit Metas Llama 4 Maverick (400 Mrd. Parameter, 4-Bit quantisiert) dauerte die Beweiserzeugung für 24 Anfragen auf einem H100-Server 223 Sekunden (~19 MB pro Beweis), die Prüfung auf normaler CPU 17-21 Sekunden. Der Kontext ist bislang auf 1.024 Tokens begrenzt; Anthropic nennt es selbst einen nicht gepflegten Prototyp.

heise.de

2. ChatGPT kann jetzt animierte GIFs erstellen

OpenAI rollt auf Basis des neuen Modells Images 2.6 eine Funktion aus, mit der ChatGPT aus Text-Prompt oder Foto animierte GIFs erzeugt, inklusive Anpassung von Tempo und einzelnen Frames - verfügbar für alle Nutzer auf Web, Desktop und Mobil. Laut OpenAI entstehen inzwischen über vier Milliarden Bilder pro Woche über ChatGPT und API, eine Milliarde mehr als im September. Für Entwickler kommen zudem zwei neue API-Varianten: das effiziente 'Flare' und das hochwertigere 'Sunburst'.

the-decoder.de

3. Anthropic weitet Text-Wasserzeichen aus - aber umgehbar

Ab 16. November erhalten auch Claude Opus 4.6, Opus 4.5, Sonnet 4.5 und Haiku 4.5 das unsichtbare Text-Wasserzeichen (Variante von Google DeepMinds SynthID-Text); bei allen vier greift es laut Anthropic jedoch nur bei Standard-Sampling-Parametern (temperature, top_p, top_k) - schon eine kleine Änderung kann unmarkierte Ausgaben erzeugen. Anthropic begründet die Einführung mit der Dezember-Frist des EU AI Act und rät zur Beibehaltung der Standardwerte für Compliance-Zwecke; eine Detection-API befindet sich in privater Vorschau.

the-decoder.de

4. Claude Smart Reports: was Vorgesetzte über die KI-Nutzung des Teams erfahren

Enterprise-Kunden können mit der neuen, standardmäßig deaktivierten Funktion bis zu 10 Berichte pro Monat erstellen, die zeigen, wie ein Team Claude nutzt, was dies zu Listenpreisen kostet und wo wiederkehrende, effizienter lösbare Muster auftreten; vertraulich eingestufte Sitzungen fließen nur aggregiert und ohne persönliche Details ein. Anthropic betont, die Berichte seien nicht zur Bewertung Einzelner gedacht - erlauben laut Artikel aber dennoch Effizienz-Rückschlüsse. Hintergrund: Laut AWS-Studie nutzen nur 15 Prozent der deutschen Unternehmen KI intensiv genug für neue Produkte/Prozesse (Vorjahr: 21 Prozent).

heise.de

Bedeutende Forschung

1. GPT-6 Astra liest und verändert Modellgewichte fremder KI-Modelle

MIT-Forscher zeigen laut the-decoder, dass GPT-6 Astra rohe Modellgewichte anderer Netze direkt lesen, interpretieren und gezielt verändern kann - ohne klassisches gradientenbasiertes Training ('Weight-Space Programming'). Bei Qwen3.5-0.8B behob Astra durch Änderung von nur 0,016 Prozent der Gewichte eine bekannte Wiederholungsschleife: MATH-500-Genauigkeit stieg von 7,9 auf 48,1 Prozent, Befolgung von Anweisungen von 21 auf 62 Prozent. Bei einem kleineren Modell (Gemma 3 270M) zeigte sich dagegen keine Verbesserung; die Forscher betonen, grundsätzlich fehlende Fähigkeiten könne Astra nicht hinzufügen.

the-decoder.de

2. CloudOpsBench: Benchmark zeigt Schwächen von KI-Agenten bei Cloud-DevOps

Ein neuer, offener Benchmark (45 Aufgaben auf AWS, Apache-2.0) testet KI-Agenten an typischen DevOps-Aufgaben wie Dienste reparieren, Ressourcen entfernen oder Zugriffsrechte einschränken. Claude Fable 5.1 löste 60 Prozent der Aufgaben, GPT-6 Astra 53 Prozent; rund 80 Prozent der Fehler sind Denkfehler (falscher Aufgabenumfang, übersehene Dienste), aber etwa 20 Prozent sind tatsächlich schädliche, teils irreversible Eingriffe in die Infrastruktur. Erweiterungen für GCP, Azure und OCI sind geplant.

the-decoder.de

Weitere gesichtete, aber ausgelassene Punkte

- Saudi Aramco übernimmt knapp die Hälfte des KI-Unternehmens Humain
  (heise.de)
- KI-Boom in den USA: Auch alte Flugzeugtriebwerke sollen jetzt Strom liefern
  (heise.de)
- OpenAI übernimmt Entwickler-Tool-Firma Pierre Computer
  (heise.de)
- itch.io löscht mehrere Terabyte KI-Slop und filtert KI-Projekte
  (heise.de)
- Linux-KI-Brille Raven Prism geht in den Verkauf - zum Luxuspreis
  (heise.de)
- Google koppelt Schul-Suchzugriff an Freigabe von KI-Tools
  (heise.de)
- t3n-Porträt: Produktmanager diktiert mit Freeflow + Claude Code
  (t3n.de)